



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Sürü İnsansız Hava Araçları ile Otonom Yangın Sahası Analizi ve Dinamik Risk Yoğunluğu Haritalama Sistemi

BİTİRME PROJESİ FİNAL RAPORU

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Dr. Öğr. Üyesi Eyüp Emre ÜLKÜ

İSTANBUL, 2026

ÖNSÖZ

Bu çalışma, Marmara Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği Bölümü lisans eğitimimizin bir parçası olan Bitirme Projesi kapsamında, "Sürü İnsansız Hava Araçları ile Otonom Yangın Sahası Analizi ve Dinamik Isı Haritalama Sistemi" başlığı altında hazırlanmıştır.

Proje fikrinin oluşmasından tasarım ve uygulama aşamalarına kadar geçen süreçte, akademik bilgi birikimi ve tecrübeleriyle bize yol gösteren, karşılaştığımız teknik zorluklarda sabırla rehberlik eden ve motivasyonumuzu her daim yüksek tutan değerli danışman hocamız Sayın Dr. Öğr. Üyesi Eyüp Emre ÜLKÜ'ye en içten teşekkürlerimizi sunarız.

Çalışmalarımızı yürütmemiz için gerekli laboratuvar olanaklarını ve teknik altyapı imkânlarını sağlayan Marmara Üniversitesi Teknoloji Fakültesi Dekanlığına ve Bilgisayar Mühendisliği Bölüm Başkanlığına şükranlarımızı sunarız.

İÇİNDEKİLER

1. GİRİŞ.....	10
1.1 Problemin Tanımı.....	11
1.2 Çalışmanın Konusu.....	13
1.3 Çalışmanın Önemi	14
1.4 Literatür Taraması	15
2. YÖNTEM.....	17
2.1 Sistem Mimarisi ve Simülasyon Ortamı	17
2.2 Veri Setinin Oluşturulması ve Etiketlenmesi	20
2.3 YOLO Tabanlı Yangın Tespit Modelinin Eğitimi.....	21
2.4 Görev Alanının Tanımlanması ve Tarama Yaklaşımı	22
2.5 Kamera Kapsama Alanına Dayalı Waypoint Üretimi	23
2.6 Waypoint Bazlı Görüntü Toplama ve Yangın Tespiti.....	24
2.7 PID Tabanlı Bounding Box İşleme Yaklaşımı	24
2.8 Derinlik Bilgisi ile Yaklaşık Alan ve Konum Hesabı	25
2.9 HSV Renk Analizi ve Yangın Risk Skoru Hesabı.....	26
2.10 Merkezî Veri Füzyonu ve Uzamsal Kümeleme	27
2.11 Risk Yoğunluk Haritası ve Harita Çıktılarının Oluşturulması.....	29
2.12 Performans Değerlendirme Ölçütleri.....	30
3. BULGULAR.....	31
3.1 Veri Setine İlişkin Bulgular	31
3.2 Yangın Tespit Modeline İlişkin Bulgular.....	33
3.3 Sürü İHA Tarama Sistemine İlişkin Bulgular	34
3.4 Tespitlerin Ortak Yapıda Birleştirilmesi ve Haritalama Bulguları	34
3.5 Kalibrasyon Senaryosuna İlişkin Bulgular	35
3.6 Genel Değerlendirme	36
3.7 Çalışmanın Kısıtları ve Gelecek Çalışmalar	37
4. KAYNAKÇA	38

ÖZET

Küresel ısınma ve iklim değişikliğinin etkisiyle giderek artan orman yangınları, mevcut müdahale yöntemlerinin yetersiz kaldığı kritik bir tehdit haline gelmektedir. Geleneksel izleme sistemleri büyük coğrafi alanları anlık olarak kapsayamamakta; geç tespit ise yangının hızla yayılmasına zemin hazırlamaktadır. Bu çalışmada, AirSim ve Unreal Engine tabanlı simülasyon ortamında çalışan, birden fazla İnsansız Hava Araçlarından oluşan otonom bir yangın tespit ve risk haritalama sistemi geliştirilmiştir. Geliştirilen sistem, her İHA'nın kendisine atanan bölgede görüntü analizi yaptığı ve elde edilen tespit sonuçlarının merkezî bir sunucuda birleştirildiği çoklu İHA yapısına dayanmaktadır.

Geliştirilen çoklu İHA sisteminde 100×100 m büyüklüğündeki simülasyon alanı üç İHA arasında bölüştürülmektedir. Her İHA, 16 m temel uçuş yüksekliği ve 90 derece kamera görüş açısı esas alınarak oluşturulan zigzag tarama rotasında hareket etmektedir. Her waypoint noktasında art arda alınan görüntüler üzerinde yangın tespiti gerçekleştirilmekte, tespitler bounding box kararlılığı, renk bilgisi ve model güven değeri bakımından değerlendirilmektedir. Tespit edilen noktalar merkezî sunucuya iletilmekte, yakın konumdaki gözlemler uzamsal kümeleme yöntemiyle birleştirilmekte ve doğrulanmış kümeler görev sırasında güncellenen OpenStreetMap tabanlı bir harita üzerinde gösterilmektedir.

Bu çalışma sonucunda, simülasyon ortamında çoklu İHA ile alan taraması gerçekleştirebilen, görüntü tabanlı yangın tespiti yapabilen ve tespit sonuçlarını merkezî olarak görselleştirebilen bütünleşik bir yazılım prototipi oluşturulmuştur. Sistem tarafından oluşturulan harita, gerçek sıcaklık ölçümüne dayalı termal harita niteliğinde olmayıp görüntü analizinden elde edilen yangın risk yoğunluğunu temsil etmektedir.

Anahtar Kelimeler: Çoklu İHA sistemi, yangın tespiti, YOLO26m, AirSim, Unreal Engine, risk haritalama, uzamsal kümeleme, OpenStreetMap.

ABSTRACT

Forest fires pose a significant threat to ecosystems, infrastructure and human safety, particularly when fire-affected regions cannot be identified and assessed in a timely manner. Conventional monitoring methods may be limited by observation frequency, fixed coverage areas or delayed access to location-specific information. This project aims to develop an autonomous multi-Unmanned Aerial Vehicle system capable of scanning a designated mission area, detecting fire regions from aerial imagery, evaluating detected fire candidates through risk scoring and visualising the resulting spatial information on a map-based interface. The proposed system was developed in a Microsoft AirSim and Unreal Engine simulation environment and consists of three UAVs operating within a distributed sensing and centralized fusion architecture. The mission area is divided among the UAVs, and each vehicle follows a zigzag coverage path generated according to camera footprint and overlap requirements. At the visited waypoint locations, the UAVs acquire consecutive images and perform local fire detection using a YOLO26m-based object detection model trained on a project-specific dataset. The dataset was generated from different simulation scenes, environmental layouts, lighting conditions and camera viewpoints, and contains 1447 training, 180 validation and 182 test images labelled under the single class of “fire”.

Since flame appearance may vary between consecutive frames, the detection process does not rely solely on individual image outputs. Repeated bounding box detections are processed using a PID-based consistency mechanism in order to obtain a more stable representation of each fire candidate. For stable detections, depth information is used to estimate approximate spatial position and area-related information, while HSV-based colour analysis provides an additional visual indicator of flame characteristics. Model confidence, colour information and approximate area information are then combined to calculate a fire risk score for each detected candidate.

The detections produced by individual UAVs are processed, which spatially close observations are clustered in order to reduce repeated representations of the same fire region. Confirmed fire clusters are visualised through a risk-density heatmap into an OpenStreetMap-based static map output. The generated heatmap does not represent direct temperature measurements; rather, it indicates the spatial concentration of detected fire risks derived from image analysis results. Model evaluation results showed that the YOLO26m model achieved an mAP@0.5 value of

0.8247 on the validation dataset and 0.7665 on the test dataset. In an initial calibration scenario containing two predefined fire locations, both fire regions were identified as confirmed clusters, while the observed positioning errors indicated that localisation performance may vary depending on viewing geometry, depth information and environmental scene conditions. Overall, the developed prototype integrates autonomous multi-UAV area scanning, image-based fire detection, risk assessment, centralized data fusion and map-based visualisation within a unified simulation framework for fire-site analysis.

Keywords: Multi-UAV system, autonomous scanning, fire detection, YOLO26m, AirSim, Unreal Engine, risk mapping, centralized data fusion, OpenStreetMap.

MARMARA ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Marmara Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği Öğrencileri Yusuf Bilal Usta, Yağız Cebail Yeşilyurt ve Ömer Kavaklı tarafından “Sürü İnsansız Hava Araçları ile Otonom Yangın Sahası Analizi ve Dinamik Risk Yoğunluğu Haritalama Sistemi” projesinin raporu 11.06.2026 tarihinde juriye sunulmuştur.

Hazırlayanlar

Yusuf Bilal Usta

Yağız Cebail Yeşilyurt

Ömer Kavaklı

Danışman: Dr. Öğr. Üyesi Eyüp Emre ÜLKÜ

ŞEKİLLER

Şekil 1. Sistem Mimarisi	18
Şekil 2. Tek bir İHA'nın iş akışı	19
Şekil 3. Veri setinin oluşturulduğu örnek bir harita	21
Şekil 4. Veri setinden örnek görüntüler. (a) Yangın içeren görüntü, (b) yangın içermeyen görüntü	21
Şekil 5. Risk yoğunluk haritası	30

TABLÖLER

Tablo 1. Nihai veri setinin eğitim, doğrulama ve test kümelerine göre dağılımı.....	20
Tablo 2. Nihai verisetinin dağılımı	32
Tablo 3. Örnek test koşusuna ait sürü İHA görev çıktıları.....	32
Tablo 4. Kalibrasyon senaryosunda yangın noktalarına ilişkin sonuçlar	35

1. GİRİŞ

Küresel ısınma, iklim değişikliği ve artan kuraklık oranları, özellikle Akdeniz kuşağında yer alan ülkelerde orman yangınlarının sıklığını, süresini ve etki alanını belirgin biçimde artırmaktadır [1–3]. Türkiye’de her yıl binlerce hektarlık orman alanı yangınlar nedeniyle kaybedilmekte; bu durum ekosistem dengesini bozmakta, biyolojik çeşitliliği azaltmakta ve ciddi ekonomik kayıplara yol açmaktadır. Mevcut erken uyarı ve izleme yöntemleri arasında uydu sistemleri, gözetleme kuleleri ve yer sensör ağları bulunsa da; bu çözümler çoğu zaman yüksek gecikme, sınırlı mekânsal/zamansal çözünürlük ve gerçek zamanlı karar desteği üretme konularında yetersiz kalmaktadır [4].

Bu nedenle yangın sahasının kısa sürede gözlemlenebilmesi, yangın görülen bölgelerin yaklaşık konumlarının belirlenebilmesi ve elde edilen bilgilerin karar vericilere anlaşılır bir biçimde sunulması önem taşımaktadır.

Yangın izleme çalışmalarında uydu görüntüleri, sabit gözetleme sistemleri ve yer tabanlı sensör ağları kullanılabilir. Bununla birlikte uydu görüntülerinde gözlem sıklığı ve çözünürlük sınırlılıkları, sabit sistemlerde ise kapsama alanının kurulum yapılan bölgeyle sınırlı kalması gibi sorunlar bulunmaktadır.

İnsansız Hava Araçları, belirlenen bölgelere yönlendirilebilmeleri, düşük irtifadan yüksek ayrıntıya sahip görüntüler elde edebilmeleri ve görev gereksinimine göre yeniden konumlandırılabilmesi nedeniyle yangın izleme uygulamalarında kullanılabilecek uygun platformlardır. Tek bir İHA ile gerçekleştirilen tarama görevlerinde geniş alanların incelenmesi uzun sürebileceğinden, birden fazla İHA’nın görev alanını paylaşarak eş zamanlı biçimde çalışması, alan kapsama süresinin azaltılması ve gözlem verisinin artırılması açısından avantaj sağlamaktadır.

Bu çalışmada, Microsoft AirSim ve Unreal Engine tabanlı simülasyon ortamında çalışan, birden fazla İHA’dan oluşan otonom bir yangın sahası analiz ve risk haritalama sistemi geliştirilmiştir. Mevcut sistem, her İHA’nın kendisine atanan bölgede görüntü tabanlı yangın tespiti gerçekleştirdiği ve elde edilen sonuçların merkezî olarak birleştirildiği dağıtık algılama ve merkezî füzyon yaklaşımına dayanmaktadır.

Geliştirilen sistemde görev alanı koordinat bilgileriyle tanımlanmakta ve simülasyon ortamında kullanılabilecek metre tabanlı koordinatlara dönüştürülmektedir. Tarama rotası, İHA’nın uçuş

yüksekliği ve aşağı yönelimli kameranın görüş açısı dikkate alınarak oluşturulmakta; her İHA kendisine atanan bölgedeki parsel merkezlerini zigzag tarama deseniyle ziyaret etmektedir.

Her İHA, waypoint noktalarında elde ettiği ardışık görüntüler üzerinde YOLO26m tabanlı yangın tespit modelini çalıştırmaktadır. Her İHA, waypoint noktalarında aldığı ardışık görüntüler üzerinde YOLO26m tabanlı yangın tespiti gerçekleştirmekte; ardışık karelerde tekrar eden tespitler PID tabanlı yöntemle birleştirilerek daha tutarlı bir yangın adayı belirlenmektedir. Bu şekilde belirlenen yangın adayları için derinlik ve renk bilgisi kullanılarak yaklaşık konum ve risk skoru hesaplanmaktadır.

Aynı yangın odağı birden fazla İHA veya farklı waypoint noktaları tarafından tekrar tespit edilebildiğinden, bireysel tespitler konumlarındaki yakınlıklara göre birleştirilmektedir. Doğrulanmış yangın bölgeleri OpenStreetMap tabanlı statik harita üzerinde gösterilmektedir. Bu çalışmada risk yoğunluk haritası, doğrudan sıcaklık ölçümünü değil, görüntü tabanlı yangın tespitlerinden ve hesaplanan risk skorlarından elde edilen yoğunluk gösterimini ifade etmektedir.

Elde edilen sistem, simülasyon ortamında görev alanını İHA'lar ile tarayabilen, yangın adaylarını merkezî biçimde değerlendirebilen ve sonuçları harita üzerinde görselleştirebilen bütünsel bir yazılım prototipi sunmaktadır.

1.1 Problemin Tanımı

Orman yangınlarının erken aşamada tespit edilmesi ve yangın görülen bölgelerin konumlarının belirlenmesi, afet yönetimi ve müdahale planlaması açısından önemli bir gereksinimdir. Yangının başlangıç aşamasında fark edilememesi, müdahale süresinin uzamasına ve etkilenen alanın büyümesine neden olabilmektedir. Mevcut izleme yöntemleri arasında yer alan uydu görüntüleri geniş alanların gözlemlenmesine imkân sağlamakla birlikte görüntüleme sıklığı ve çözünürlük bakımından sınırlılıklar taşıyabilmektedir. Sabit gözetleme sistemleri ve yer sensörleri ise yalnızca kuruldukları bölgelerde gözlem yapabilmekte ve değişen olay alanlarına dinamik biçimde yönlendirilememektedir.

İnsansız Hava Araçları, düşük irtifadan görüntü elde edebilme, belirlenen bölgelere yönlendirilebilme ve görev alanını farklı noktalardan gözlemleyebilme özellikleri sayesinde yangın tespit çalışmalarında kullanılabilecek hareketli algılama platformlarıdır. Literatürde

İHA görüntüleri üzerinde CNN ve YOLO tabanlı yöntemlerle orman veya arazi yangınlarının tespit edilmesine yönelik çeşitli çalışmalar bulunmaktadır. RGB ve kızılötesi görüntülerin kullanıldığı veri seti çalışmaları, CNN tabanlı erken yangın tespit yaklaşımları ve YOLO ailesinin farklı sürümleriyle gerçekleştirilen uygulamalar, görüntü tabanlı yangın tespitinin İHA platformlarında uygulanabilir olduğunu göstermektedir [5–12].

Bununla birlikte geniş bir görev alanının yalnızca tek bir İHA ile taranması, kapsama süresinin uzamasına ve farklı bölgelerden eş zamanlı veri elde edilememesine neden olabilmektedir. Bu çalışmanın odaklandığı problem, yangının yalnızca görüntü üzerinde tespit edilmesi değil, çoklu İHA kullanılarak görev alanının sistematik biçimde taranması, farklı görüntülerden elde edilen tespitlerin konumsal olarak ilişkilendirilmesi ve yangın bölgelerinin risk yoğunluğu biçiminde haritalandırılmasıdır. Sürü İHA kullanımında görev alanının araçlar arasında uygun biçimde bölüştürülmesi, her İHA için verimli bir tarama rotası oluşturulması ve aynı yangının farklı waypoint noktalarından veya farklı İHA'lar tarafından tekrar tespit edilmesi durumunda bu gözlemlerin tek bir anlamlı sonuç altında birleştirilmesi gerekmektedir. Bunun yanında alevlerin şekil ve parlaklık bakımından değişken olması, simülasyon sahnesindeki parlak objelerin yangın görünümüne benzer özellikler gösterebilmesi ve ardışık karelerde elde edilen bounding box sonuçlarının farklılaşabilmesi, tespit sürecinde kararsız veya hatalı sonuçların oluşmasına yol açabilmektedir. Ayrıca görüntü üzerinde tespit edilen bir yangın adayının görev alanındaki yaklaşık konumunun belirlenmesi ve risk düzeyiyle ilişkilendirilmesi, yalnızca nesne tespiti yapan bir sistemden daha kapsamlı bir analiz altyapısı gerektirmektedir.

Bu kapsamda geliştirilen sistemde, simülasyon ortamında tanımlanan görev alanı üç İHA arasında paylaştırılmakta ve her İHA kendisine atanan bölgede zigzag tarama rotası izlemektedir. Waypoint noktalarında elde edilen ardışık görüntüler üzerinde YOLO26 tabanlı yangın tespit modeli çalıştırılmakta; tekrar eden tespitler PID tabanlı yöntemle işlenerek daha tutarlı bir yangın adayı belirlenmektedir. Kararlı tespitler için derinlik ve renk bilgisi kullanılarak yaklaşık konum ve risk skoru hesaplanmakta, İHA'lardan gelen gözlemler merkezî sunucuda konumsal yakınlıklarına göre kümelenmekte ve doğrulanan yangın bölgeleri harita üzerinde görselleştirilmektedir.

Bu bağlamda çalışmanın temel araştırma sorusu şu şekilde ifade edilmektedir: “Sürü İHA tabanlı otonom tarama ve merkezî veri füzyonu yaklaşımı, simülasyon ortamında yangın bölgelerinin görüntü üzerinden tespit edilmesi, tekrarlı gözlemlerin birleştirilmesi ve

elde edilen risk bölgelerinin harita üzerinde gösterilmesi görevlerini ne ölçüde yerine getirebilmektedir?”

Bu temel soru doğrultusunda çalışmada; proje kapsamında oluşturulan veri setiyle eğitilen yangın tespit modelinin başarımı, kamera kapsama alanına dayalı tarama rotasının sürü İHA görevinde kullanılması, derinlik ve renk bilgilerinin risk değerlendirme sürecine dahil edilmesi, tekrarlı yangın tespitlerinin merkezî kümeleme yoluyla birleştirilmesi ve elde edilen sonuçların harita çıktısı biçiminde sunulması incelenmektedir.

1.2 Çalışmanın Konusu

Bu çalışma, orman yangını senaryolarında kullanılmak üzere, simülasyon ortamında çalışan sürü İnsansız Hava Aracı tabanlı bir yangın tespit ve risk haritalama sisteminin geliştirilmesini konu almaktadır. Proje kapsamında Microsoft AirSim ve Unreal Engine ortamında oluşturulan görev alanı, üç İHA tarafından eş zamanlı biçimde taranmaktadır. Her İHA, kendisine atanan alt bölgede kamera kapsama alanına göre oluşturulan zigzag tarama rotasını izlemekte ve waypoint noktalarında elde ettiği görüntüler üzerinde yangın tespiti gerçekleştirmektedir. Yangın tespit sürecinde, proje kapsamında oluşturulan veri setiyle eğitilen YOLO26m tabanlı nesne tespit modeli kullanılmaktadır. İHA kamerasından alınan ardışık görüntülerde belirlenen yangın adayları, tek bir görüntü karesine bağlı kalınmadan değerlendirilmekte; tekrar eden bounding box sonuçları PID tabanlı yöntemle işlenerek daha tutarlı bir tespit çıktısı elde edilmektedir. Kararlı biçimde belirlenen yangın adayları için derinlik verisi kullanılarak yaklaşık konum ve alan bilgisi hesaplanmakta, HSV renk analizi ile elde edilen renk bilgisi model güveni ve alan bilgisiyle birlikte değerlendirilerek her tespit için bir risk skoru oluşturulmaktadır.

Sistemde her İHA tarafından elde edilen tespitler merkezî olarak aktarılmaktadır. Aynı yangın odağının farklı waypoint noktalarından veya farklı İHA'lar tarafından tekrar tespit edilebilmesi nedeniyle, merkezî olarak konumsal yakınlığa dayalı kümeleme işlemi uygulanmaktadır. Böylece tekrarlı gözlemler aynı yangın bölgesi altında birleştirilmekte ve belirlenen doğrulama koşullarını sağlayan yangın kümeleri harita çıktısına aktarılmaktadır. Oluşturulan OpenStreetMap tabanlı statik harita, yangın görülen bölgelerin konumsal olarak incelenmesine olanak sağlamaktadır.

Bu yönüyle çalışma, yalnızca görüntü üzerinde yangın tespiti gerçekleştiren bir model geliştirme çalışması değildir. Çalışma; sürü İHA ile alan tarama, görüntü tabanlı yangın tespiti, tespitlerin risk değeriyle ilişkilendirilmesi, merkezî veri füzyonu ve harita tabanlı görselleştirme bileşenlerini tek bir simülasyon prototipi içerisinde bir araya getirmektedir. Geliştirilen sistemde üretilen ısı haritası, doğrudan sıcaklık ölçümüne dayalı termal bir harita olmayıp, tespit edilen yangın bölgelerine ilişkin risk yoğunluğunun konumsal gösterimini ifade etmektedir.

1.3 Çalışmanın Önemi

Orman yangınlarında erken tespit ve olay alanına ilişkin güncel bilgi elde edilmesi, müdahale sürecinin etkin biçimde planlanması açısından önem taşımaktadır. İHA görüntüleri üzerinde CNN ve YOLO tabanlı yöntemlerin yangın tespitinde kullanılabilirliğine ilişkin çalışmalar literatürde yer almaktadır [5–12]. Bununla birlikte geniş alanların izlenmesinde yalnızca tek bir İHA'nın kullanılması, kapsama süresi ve eş zamanlı gözlem kapasitesi bakımından sınırlılıklar oluşturabilmektedir.

Bu çalışma, yangın tespit modelini sürü İHA tarama ve merkezî haritalama altyapısı içerisinde kullanması bakımından önem taşımaktadır. Çalışmanın ilk önemli yönü, görev alanının birden fazla İHA arasında paylaştırılarak taranmasıdır. Üç İHA'nın kendi sorumluluk bölgelerinde eş zamanlı biçimde hareket etmesi, tek bir aracın tüm alanı sıralı biçimde taramasına kıyasla görev sürecinin daha düzenli ve paralel biçimde yürütülmesine olanak sağlamaktadır. Kamera kapsama alanına bağlı olarak oluşturulan zigzag rota yapısı, görev alanının sistematik biçimde gözlemlenebilmesi için uygulanabilir bir tarama yaklaşımı sunmaktadır.

Çalışmanın ikinci önemli yönü, yangın tespitinin yalnızca tek karede üretilen model sonucuna dayandırılmamasıdır. Alevlerin değişken görünümü, parlak çevresel objeler ve görüntü üzerindeki konum değişimleri, tespit çıktılarında dalgalanmalara neden olabilmektedir. Bu nedenle ardışık görüntülerde tekrar eden tespitlerin değerlendirilmesi, derinlik bilgisinin yaklaşık konum ve alan hesabında kullanılması ve HSV renk analizinin risk değerlendirmesine dahil edilmesi, sistemin yalnızca nesne tespitine dayalı basit bir yapıdan daha kapsamlı bir analiz altyapısına dönüşmesini sağlamaktadır.

Çalışmanın üçüncü önemli yönü, farklı İHA'lerden ve farklı gözlem noktalarından elde edilen tespitlerin merkezî olarak birleştirilmesidir. Aynı yangın odağının tekrar tekrar tespit edilmesi durumunda, her gözlemin bağımsız bir yangın olarak gösterilmesi harita üzerinde yanıltıcı yoğunluklar oluşturabilir. Geliştirilen merkezî kümeleme yaklaşımı, yakın konumdaki tespitleri aynı yangın bölgesi altında birleştirerek sonuçların daha düzenli ve yorumlanabilir biçimde sunulmasına katkı sağlamaktadır.

Son olarak çalışma, gerçek donanım kullanılmadan önce farklı görev senaryolarının simülasyon ortamında denenmesine imkân sağlayan modüler bir yazılım prototipi ortaya koymaktadır. Oluşturulan veri seti, eğitilen yangın tespit modeli, sürü İHA görev mimarisi ve haritalama çıktıları birlikte değerlendirildiğinde proje; otonom sistemler, görüntü işleme ve afet yönetimi uygulamalarının bütünleştirildiği bir bitirme projesi niteliği taşımaktadır. Geliştirilen altyapı, sonraki çalışmalarda farklı görev alanları, farklı yangın yerleşimleri ve gerçek İHA sistemlerine uyarlama çalışmalarının yürütülmesi için temel oluşturabilecek bir yapı sunmaktadır.

1.4 Literatür Taraması

İHA tabanlı yangın tespiti ve sürü İHA sistemlerine ilişkin literatür, bu çalışmanın üç temel bileşeni olan görüntü tabanlı yangın tespiti, çoklu İHA tarama mimarisi ve dağıtık öğrenme yaklaşımları açısından incelenmiştir.

Görüntü tabanlı yangın tespiti. İHA görüntüleri üzerinde derin öğrenme yöntemleriyle yangın tespitine yönelik çeşitli çalışmalar yürütülmüştür. Chen ve diğerleri [6], İHA ile toplanan RGB ve kızılötesi görüntülerden oluşan kapsamlı bir veri seti sunmuş; bu veri seti üzerinde gerçekleştirilen yangın tespiti ve izleme çalışmalarının, geleneksel uydu ve kule tabanlı sistemlerin yetersiz kaldığı erken tespit senaryolarında uygulanabilir olduğunu ortaya koymuştur. Georgiev ve diğerleri [9], evrişimli sinir ağı tabanlı otonom bir erken yangın tespit yaklaşımı geliştirmiş; sistemin insan müdahalesi gerektirmeksizin yüksek güvenilirlikte çalışabildiğini ve elde edilen verilerin gerçek zamanlı olarak web tabanlı bir platform üzerinden izlenebildiğini göstermiştir. Bakirci ve Bayraktar [8], YOLOv9 algoritmasını gerçek zamanlı orman yangını tespitine uyarlamış; Ma ve diğerleri [11] ise optimize edilmiş YOLOv8s mimarisini çayır yangınlarının İHA üzerinden tespiti ve konumlandırılmasına uygulamıştır. Xie ve diğerleri [5] çift ışık görüntüsü kullanarak İHA tabanlı yangın tespitini ele alırken, Mughal

ve diğerleri [12] orman yangınlarında duman ve alev tespitini bütünleşik bir yapıda incelemiştir. Bu çalışmalar görüntü tabanlı yangın tespitinin İHA platformlarında uygulanabilirliğini göstermekte; bununla birlikte büyük ölçüde tek İHA senaryolarına odaklanmakta ve sistematik çoklu alan taraması ile risk haritalama bileşenlerini genellikle kapsam dışında bırakmaktadır.

Çoklu İHA tarama ve sürü mimarisi. Geniş alanların etkili biçimde taranabilmesi için birden fazla İHA'nın koordineli kullanımı üzerine de çalışmalar yürütülmüştür. Papakostas ve diğerleri [20], orman yangını gibi afet senaryolarında ilk müdahale ekiplerine destek sağlamak amacıyla otonom İHA sürüsü oluşumlarıyla optimize alan kapsamı sunan bir sistem geliştirmiş; sensörlerin birden fazla araca dağıtılmasının görev süresini uzattığını ve veri erişilebilirliğini artırdığını göstermiştir. Li ve diğerleri [13], İHA kümelerinin nesne tespiti görevlerinde dayanıklılığını artırmak amacıyla hiyerarşik bir federatif öğrenme çerçevesi önermiş; İHA'ların üç boyutlu grafik yapısıyla gruplanarak görev paylaşımının optimize edilebildiğini ortaya koymuştur. Bu çalışmalar, çoklu İHA mimarilerinin tek araçlı sistemlere kıyasla alan kapsama kapasitesini artırdığını ve algılama yükünün araçlar arasında dağıtılabildiğini göstermektedir.

Dağıtık öğrenme yaklaşımları. Çoklu İHA sistemlerinde veri paylaşımı ve model güncelleme süreçlerini ele alan dağıtık öğrenme çalışmaları da literatürde yer almaktadır. Ding ve diğerleri [15], İHA sürüleri için federatif öğrenme, çok etmenli pekiştirmeli öğrenme ve dağıtık çıkarım gibi dağıtık makine öğrenmesi yaklaşımlarını kapsamlı biçimde incelemiş; bu yöntemlerin İHA sürülerine uygulanma senaryolarını çok yönlü uzaktan gözetleme ve hedef takibi dahil çeşitli uygulama alanlarıyla tartışmıştır. Zhang ve Hanzo [14], federatif öğrenme destekli çoklu İHA ağlarında model güncelleme ve iletişim verimliliğini değerlendirmiştir. El Haffy ve diğerleri [16], İHA ağlarında federatif ve derin öğrenme yöntemlerini orman yangını gözetlemesine uygulamıştır. Projenin önceki aşamalarında federatif öğrenme tabanlı bir yapı değerlendirilmiş olmakla birlikte, dördüncü ara rapor döneminde uygulama kapsamı çalışan bir sürü İHA tarama ve yangın haritalama prototipi oluşturmaya yönelik olarak güncellenmiştir. Mevcut sistemde İHA'lar önceden eğitilmiş ortak bir yangın tespit modelini kullanarak çıkarım gerçekleştirmekte ve tespit sonuçlarını merkezi veri füzyonu yapısında birleştirmektedir.

Bu literatür incelemesi, görüntü tabanlı yangın tespiti ve İHA otomasyon alanlarının her birinde kayda değer çalışmalar bulunduğunu; ancak sistematik sürü İHA taraması, görüntü tabanlı risk skorlaması ve merkezi haritalamayı tek bir bütünleşik prototipte bir araya getiren çalışmaların sınırlı kaldığını ortaya koymaktadır. Bu çalışma, söz konusu bileşenleri simülasyon ortamında birleştirerek bu boşluğu doldurmayı hedeflemektedir.

2. YÖNTEM

Bu bölümde, geliştirilen sürü İnsansız Hava Aracı (İHA) tabanlı otonom yangın tespit ve risk haritalama sisteminin tasarımı, bileşenleri ve çalışma adımları ayrıntılı olarak ele alınmaktadır. Sistem; simülasyon ortamının kurulmasından görev alanının belirlenmesine, görüntü tabanlı yangın tespitinden tespit sonuçlarının merkezî olarak birleştirilmesine kadar uzanan birbiriyle bütünleşik aşamalardan oluşmaktadır. Her bir aşama, sürü yapısının otonom biçimde alan tarayabilmesi, yangın adaylarını güvenilir şekilde belirleyebilmesi ve elde edilen sonuçları anlamlı bir harita çıktısına dönüştürebilmesi hedefi doğrultusunda tasarlanmıştır.

Yöntem, dağıtık algılama ve merkezî veri füzyonu ilkesine dayanmaktadır. Bu yaklaşımda, görev alanı birden fazla İHA arasında paylaştırılmakta; her İHA kendisine atanan bölgede bağımsız olarak tarama yapmakta, görüntü analizi yoluyla yangın tespiti gerçekleştirmektedir. Bireysel İHA'lardan gelen tespitler merkezde birleştirilerek tekrarlı gözlemlerden arındırılmakta ve doğrulanmış yangın bölgeleri tek bir harita üzerinde gösterilmektedir.


İzleyen alt bölümlerde, öncelikle sistemin genel mimarisi ve simülasyon ortamı tanıtılmakta; ardından veri setinin oluşturulması, yangın tespit modelinin eğitimi, görev alanının tanımlanması ve tarama yaklaşımı, görüntü toplama ve tespit süreçleri, tespitlerin kararlı hâle getirilmesi, yaklaşık konum ve alan hesabı, risk skorumla, merkezî veri füzyonu ile risk yoğunluk haritasının oluşturulması adımları sırasıyla açıklanmaktadır. Son olarak, geliştirilen sistemin değerlendirilmesinde kullanılan performans ölçütlerine yer verilmektedir.

2.1 Sistem Mimarisi ve Simülasyon Ortamı


Bu çalışmada, orman yangını senaryolarının gerçek donanım kullanılmadan modellenenebilmesi ve geliştirilen algoritmaların kontrollü koşullar altında sınanabilmesi amacıyla simülasyon tabanlı bir yöntem benimsenmiştir. Sistem, Microsoft AirSim ve Unreal Engine ortamında oluşturulan görev sahasında çalışacak biçimde geliştirilmiştir. AirSim, sürü İHA kontrolüne, kamera görüntülerinin alınmasına ve araç konumlarının izlenmesine olanak sağlaması nedeniyle tercih edilmiştir. Unreal Engine ise farklı arazi görünümünün, çevresel objelerin ve yangın görsellerinin oluşturulabildiği sanal görev ortamının hazırlanmasında kullanılmıştır. Güncel sistem mimarisi, üç İHA'nın aynı görev alanında eş zamanlı biçimde çalıştığı dağıtık algılama ve merkezî veri füzyonu yaklaşımına dayanmaktadır. İHA'lar, kendisine atanan alt

bölgede bağımsız olarak hareket etmekte ve elde ettiği görüntüler üzerinde yangın tespit işlemini yerel olarak gerçekleştirmektedir. İHA'lerden elde edilen tespit sonuçları birleştirilmekte ve harita çıktısına dönüştürülmektedir.

Projenin önceki aşamalarında federatif öğrenme tabanlı bir yapı değerlendirilmiş olmakla birlikte, dördüncü ara rapor döneminde uygulama kapsamı çalışan bir sürü İHA tarama ve yangın haritalama prototipi oluşturulmasına odaklanacak biçimde güncellenmiştir. Bu nedenle mevcut sistemde İHA'lar arasında model ağırlığı paylaşımı veya federatif model güncellemesi yapılmamakta; tüm İHA'lar önceden eğitilmiş yangın tespit modelini kullanarak çıkarım gerçekleştirmekte ve tespit sonuçlarını tek bir noktada birleştirmek üzere yollamaktadırlar. Bu sayede nihai risk yoğunluk haritası oluşturulmaktadır. Şekil 1'de sistem mimarisi ve Şekil 2'de ise sistemdeki tek bir İHA üzerinde yapılan iş akışı sunulmaktadır. Sistem mimarisi, dağıtık algılama ve merkezî veri füzyonu yaklaşımı üzerine kuruludur. Her İHA, AirSim ortamından kamera görüntülerini almakta, kendi üzerinde YOLO26m tabanlı yangın tespiti yapmakta, ardışık karelerde elde edilen bbox sonuçlarını PID tabanlı yöntemle kararlı hâle getirmekte ve yangın adayları için risk skoru hesaplamaktadır. Her İHA tarafından üretilen tespitler ortak bir sonuç kuyruğu üzerinde birleştirilmektedir. Gelen tespitler minimum skor filtresinden geçmekte, konumsal yakınlıklarına göre kümelenmekte, küme güven değeri hesaplanmakta ve doğrulanmış yangın kümeleri risk yoğunluk haritası ile OpenStreetMap tabanlı statik harita çıktısına dönüştürülmektedir.



Şekil 1. Sistem Mimarisi



Şekil 2. Tek bir İHA'nın iş akışı

2.2 Veri Setinin Oluşturulması ve Etiketlenmesi

Yangın tespit modelinin eğitilebilmesi amacıyla proje kapsamında özgün bir görüntü veri seti oluşturulmuştur. Görüntüler, AirSim simülasyon ortamında İHA kamerası aracılığıyla elde edilmiştir. Veri toplama aşamasında modelin yalnızca tek bir sahne görünümüne bağlı kalmasını önlemek amacıyla farklı dünya assetleri, ağaç ve bitki yerleşimleri, arazi görünümüleri, güneş açıları, aydınlatma koşulları ve kamera bakış açıları kullanılmıştır. Toplanan görüntüler üzerinde yangın bölgeleri bounding box yöntemiyle etiketlenmiş ve veri setinde yalnızca “fire” sınıfı kullanılmıştır. İlk etiketleme aşamasında farklı kişiler tarafından yapılan işaretlemelerde kutu sınırlarının değişebilmesi, birbirine yakın alev parçalarının farklı biçimlerde etiketlenmesi ve bazı parlak bölgelerin yangınla karıştırılabilmesi gibi sorunlar belirlenmiştir. Bu nedenle veri seti yeniden incelenmiş, yakın yangın bölgelerinin gereksiz biçimde ayrı kutularla gösterildiği örneklerde kutular birleştirilmiş ve yangın görünümünün yeterince belirgin olmadığı görüntüler veri setinden çıkarılmıştır. Yeniden düzenleme sonucunda oluşturulan nihai veri setinin eğitim, doğrulama ve test kümelerine göre dağılımı Tablo 1’de verilmiştir.


Tablo 1. Nihai veri setinin eğitim, doğrulama ve test kümelerine göre dağılımı

Veri Kümesi	Görüntü Sayısı	Oran (%)
Eğitim (Train)	1447	79,99
Doğrulama (Validation)	180	9,95
Test	182	10,06
Toplam	1809	100

Eğitim kümesi model parametrelerinin öğrenilmesinde, doğrulama kümesi eğitim sürecinin izlenmesinde ve model seçiminin desteklenmesinde, test kümesi ise eğitilen modelin daha önce görmediği örneklerdeki başarımının değerlendirilmesinde kullanılmıştır. Veriseti oluştururken çeşitli Unreal Engine haritaları kullanılmıştır. Örnek bir harita Şekil 2’de verilmiştir. Veri setinden seçilen örnek görüntüler ise Şekil 3’te gösterilmiştir.



Şekil 3. Veri setinin oluşturulduğu örnek bir harita



Şekil 4. Veri setinden örnek görüntüler. (a) Yangın içeren görüntü, (b) yangın içermeyen görüntü

2.3 YOLO Tabanlı Yangın Tespit Modelinin Eğitimi

Görüntüler üzerinde yangın nesnesinin belirlenmesi amacıyla YOLO26 mimarisinin farklı model büyüklükleri değerlendirilmiştir. İlk eğitim deneyinde daha yüksek parametre sayısına sahip YOLO26x modeli kullanılmıştır. Bu deneyde AdamW optimizasyon algoritması ve

başlangıç öğrenme oranı olarak 0,001 değeri tercih edilmiş, eğitim süreci erken durdurma mekanizması sonucunda hedeflenen epoch sayısından önce tamamlanmıştır. Sonraki deneylerde, görev sırasında birden fazla İHA tarafından çıkarım yapılacağı dikkate alınarak daha düşük parametre sayısına sahip YOLO26m modeli kullanılmıştır. YOLO26m eğitiminde başlangıç öğrenme oranı 0,0003 olarak belirlenmiş ve veri artırma işlemleri genişletilmiştir. Bu kapsamda görüntülerin döndürülmesi, yatay ve düşey çevrilmesi, kesme dönüşümü uygulanması, renk doygunluğunun değiştirilmesi, mosaic, mixup ve copy paste tabanlı veri artırma yöntemlerinden yararlanılmıştır. İlk YOLO26m deneyi sınırlı epoch sayısı ile ön değerlendirme amacıyla gerçekleştirilmiş, ardından aynı mimari daha uzun eğitim süresi ve artırılmış patience değeriyle yeniden eğitilmiştir.

Sürü İHA görev sistemine entegre edilen model olarak, eğitim ve test kayıtları üzerinden en uygun sonucu veren YOLO26m tabanlı model tercih edilmiştir. Model performansına ilişkin precision, recall, mAP@0.5 ve mAP@0.5:0.95 değerleri Bulgular bölümünde ayrıca sunulmuştur.

2.4 Görev Alanının Tanımlanması ve Tarama Yaklaşımı

Projenin geliştirme sürecinde iki farklı tarama yaklaşımı üzerinde çalışılmıştır. İlk aşamada, dört köşe noktası enlem ve boylam bilgileriyle verilen bir alanı AirSim koordinatlarına dönüştüren ve tek İHA için parsel merkezli zigzag rota oluşturan bir tarama modülü geliştirilmiştir. Bu modül, dışarıdan verilen coğrafi alanların kamera kapsama alanına bağlı olarak parsellenebilmesi amacıyla hazırlanmıştır.

Güncel sürü İHA uygulamasında ise görev alanı, simülasyon ortamında metre cinsinden tanımlanan sınırlar üzerinden ele alınmaktadır. Kullanılan görev alanı 100×100 metre boyutunda olup üç İHA arasında alt bölgelere ayrılmaktadır. Her İHA, kendisine atanan bölgedeki waypoint noktalarını takip ederek eş zamanlı tarama görevini yürütmektedir. Bu yaklaşım, GPS tabanlı tek İHA tarama modülünde geliştirilen parsel merkezli rota mantığının sürü İHA görev mimarisine uyarlanmış biçimidir.

Tarama alanının araçlar arasında paylaşılmasında alan X eksenine boyunca üç alt bölgeye ayrılmaktadır. Her İHA yalnızca kendisine atanan şeritte görev yaparak diğer İHA'larla aynı

alanı gereksiz biçimde tekrar taramadan paralel gözlem gerçekleştirmektedir. Bununla birlikte görüntü kapsama alanlarının örtüşmesi ve yangının bölge sınırlarına yakın bulunması durumlarında aynı yangının birden fazla İHA tarafından tespit edilebilmesi mümkündür. Bu durum, merkezî füzyon aşamasında değerlendirilmek üzere sistem tasarımında dikkate alınmıştır.

2.5 Kamera Kapsama Alanına Dayalı Waypoint Üretimi

İHA'ların takip edeceği tarama rotası, kameranın zeminde kapsadığı alan dikkate alınarak oluşturulmaktadır. Sürü İHA sisteminde temel uçuş yüksekliği 16 metre ve kamera görüş açısı 90 derece olarak tanımlanmıştır. Aşağı yönelimli kameranın tek görüntüde kapsadığı teorik zemin genişliği aşağıdaki bağıntıyla hesaplanmaktadır:

$$Kapsama\ genişliği = 2 \times h \times \tan(FOV/2)$$

Burada h uçuş yüksekliğini, FOV ise kameranın yatay görüş açısını ifade etmektedir. Kullanılan sistem parametreleri altında tek görüntünün zeminde yaklaşık 32×32 metre alanı kapsayacağı hesaplanmaktadır. Ardışık görüntüler arasında yeterli örtüşme sağlanarak yangın bölgelerinin kaçırılma olasılığının azaltılması amacıyla örtüşme oranı yüzde 75 olarak belirlenmiştir. Bu nedenle nominal waypoint adımı aşağıdaki şekilde elde edilmektedir:

$$Waypoint\ Adımı = Kapsama\ Genişliği \times (1 - Örtüşme\ Oranı)$$

Bu hesaplama sonucunda nominal waypoint aralığı yaklaşık 8 metre olarak belirlenmektedir. Her İHA için kendisine ayrılan alt bölgede parsel merkezlerine karşılık gelen waypoint noktaları oluşturulmakta ve bu noktalar boustrophedon, diğer adıyla zigzag tarama sırasına göre düzenlenmektedir. Zigzag rota yapısında bir satır bir yönde taranırken izleyen satır ters yönde taranmakta, böylece satırlar arası geçişlerde gereksiz geri dönüş hareketlerinin azaltılması amaçlanmaktadır.

Görev sırasında İHA'ların aynı irtifada çalışmasından kaynaklanabilecek çakışma riskini azaltmak amacıyla küçük yükseklik ofsetleri uygulanmıştır.

2.6 Waypoint Bazlı Görüntü Toplama ve Yangın Tespiti

Her İHA, kendisine atanan rota üzerindeki waypoint noktasına ulaştığında görüntü toplama ve yangın tespit işlemini başlatmaktadır. Güncel sürü İHA sisteminde her waypoint noktasında 12 ardışık görüntü karesi değerlendirilmekte ve bu görüntüler üzerinde YOLO26m modeli çalıştırılmaktadır. Tek bir kare üzerinden tespit yapılması yerine ardışık görüntü dizilerinin kullanılması, geçici görüntü bozulmalarının ve tek kareye özgü hatalı tespitlerin etkisinin azaltılması amacıyla tercih edilmiştir.

YOLO modeli tarafından üretilen tespit sonuçları içerisinde belirlenen güven eşiğini sağlayan yangın adayları alınmaktadır. Veri setinde yalnızca “fire” sınıfı kullanılmış olmakla birlikte, kod yapısı ileride farklı yangın göstergelerinin eklenebilmesine olanak sağlayacak biçimde düzenlenmiştir. Her yangın adayı için bounding box koordinatları ve model güven değeri elde edilmekte, bu sonuçlar ardışık karelerde izlenerek bir sonraki analiz aşamasına aktarılmaktadır. Projenin önceki tek İHA tabanlı tarama modülünde her parsel merkezinde 40 karelik görüntü dizisi kullanılmıştır. Sürü İHA entegrasyonunda ise üç İHA’nın eş zamanlı çalışması ve görev süresinin yönetilebilir tutulması amacıyla analiz penceresi 12 kare olarak yapılandırılmıştır.

2.7 PID Tabanlı Bounding Box İşleme Yaklaşımı

Yangın alevleri sabit geometrik sınırlara sahip nesneler olmadığından, aynı yangın odağı ardışık görüntülerde farklı büyüklük ve konumlarda bounding box sonuçları oluşturabilmektedir. İHA hareketi, alevin görsel değişimi ve çevresel parlaklık etkileri de tespit kutularındaki dalgalanmayı artırabilmektedir. Bu nedenle sistemde tek karede elde edilen bounding box değerleri doğrudan kullanılmamakta, aynı yangın adayına ilişkin tekrar eden tespitler ardışık görüntüler boyunca izlenmektedir.

Aynı yangın adayına ait bounding box sonuçlarının eşleştirilmesinde kutular arasındaki kesişim oranı esas alınmaktadır. Birbirleriyle yeterli düzeyde örtüşen bounding box sonuçları aynı tespit izi altında değerlendirilmektedir. Tespit izine ait alan değerlerindeki ani değişimlerin etkisini azaltmak amacıyla PID tabanlı bir düzenleme yaklaşımı uygulanmaktadır. Bu yaklaşımda geçmiş gözlemlerin merkezi eğilimi referans alınmakta ve yeni ölçümlerdeki dalgalanmaların nihai bounding box sonucu üzerindeki etkisi azaltılmaktadır.

Aykırı bounding box alanlarının tespit sonucunu bozmasını önlemek amacıyla medyan mutlak sapma temelli bir filtreleme yaklaşımından yararlanılmaktadır. Yeterli sayıda tekrar gözlenen ve kararlı biçimde takip edilebilen yangın adayları, derinlik ve risk değerlendirmesi aşamalarında kullanılmaktadır. Ayrıca görüntü kenarına çok yakın tespitlerin konumsal hesaplamada daha fazla hata oluşturabileceği dikkate alınarak, kenar bölgesindeki bounding box sonuçları kalite değerlendirmesinde daha düşük ağırlıkla ele alınmaktadır.

PID tabanlı bounding box işleme yaklaşımında amaç, yangın adayına ait kutu alanının ardışık karelerde ani biçimde büyüüp küçülmesini azaltmak ve daha kararlı bir temsil elde etmektir. Bu çalışmada PID parametreleri $K_p = 0,35$, $K_i = 0,08$ ve $K_d = 0,10$ olarak belirlenmiştir. Parametre seçiminde öncelikli hedef, kutu alanındaki değişimlere yeterince hızlı tepki verebilen fakat tek karelik sapmalara aşırı duyarlı olmayan bir yapı elde etmektir. Bu nedenle oransal katsayı K_p , mevcut hata değerine orta düzeyde tepki verecek şekilde seçilmiştir. İntegral katsayı K_i daha düşük tutulmuş, böylece geçmiş hata birikiminin sistem üzerinde aşırı düzeltme üretmesi engellenmiştir. Türev katsayısı K_d ise ani değişimleri sönümlemek ve bounding box alanındaki hızlı dalgalanmaları azaltmak amacıyla kullanılmıştır.

PID çıktısı $[-0,30, 0,30]$ aralığında sınırlandırılmıştır. Bu sınırlama, tek bir karede oluşabilecek hatalı veya aşırı büyük/küçük bbox sonucunun nihai alan kestirimini bozmasını önlemek amacıyla uygulanmıştır. Parametreler, simülasyon ortamında farklı yangın görünüşleri ve kamera konumları üzerinde yapılan denemelerde bbox kararlılığı, tespit sürekliliği ve aşırı düzeltme davranışı dikkate alınarak deneysel olarak seçilmiştir. Bu nedenle kullanılan PID katsayıları, kesin optimum değerler olarak değil, mevcut simülasyon senaryosu için kararlı sonuç veren uygulama parametreleri olarak değerlendirilmelidir.

2.8 Derinlik Bilgisi ile Yaklaşık Alan ve Konum Hesabı

YOLO modeli ve ardışık kare değerlendirmesi sonucunda kararlı biçimde belirlenen yangın adayları için derinlik verisi kullanılmaktadır. Derinlik kamerası, tarama alanının parsellenmesi veya waypoint rotasının oluşturulması aşamasında kullanılmamaktadır. Bu veri, yalnızca yangın adayı tespit edildikten sonra, ilgili bölgenin yaklaşık fiziksel büyüklüğünün ve görev alanındaki yaklaşık konumunun hesaplanmasına destek olmak amacıyla kullanılmaktadır. Derinlik görüntüsü üzerinde yangın adayının temsil edici merkez pikseline karşılık gelen

mesafe değeri alınmaktadır. Elde edilen mesafe değeri, kamera görüş açısı ve görüntü çözünürlüğü ile birlikte değerlendirilerek bounding box boyutlarının metre cinsinden yaklaşık karşılığı hesaplanmaktadır. Bu işlemde piksel başına düşen fiziksel uzunluk değeri aşağıdaki bağıntıya göre belirlenmektedir:

$$\text{Piksel Başına Uzunluk} = 2 \times d \times \tan(FOV/2) / \text{Görüntü Genişliği}$$

Burada d, derinlik görüntüsünden elde edilen yaklaşık mesafe değerini ifade etmektedir. Bounding box genişliği ve yüksekliği bu değerle ilişkilendirilerek yangın adayının yaklaşık alan bilgisi oluşturulmaktadır. Hesaplanan alan, doğrudan gerçek yangın yüzeyinin kesin ölçümü olarak değil, risk değerlendirmesinde kullanılacak yaklaşık büyüklük bilgisi olarak kabul edilmektedir.

Yangın adayının konumsal karşılığının belirlenmesinde görüntü merkezine göre piksel ofseti ve derinlik bilgisi kullanılmaktadır. İHA'nın yönelimi dikkate alınarak bu ofsetler görev alanındaki kuzey ve doğu doğrultularına dönüştürülmektedir. Ardından yangın adayının yaklaşık GPS koordinatı elde edilmektedir. Derinlik verisinin geçersiz veya kullanılamaz olduğu durumlarda ise İHA'nın görev irtifası yaklaşık mesafe değeri olarak kullanılmaktadır. Bu nedenle sistemin konum çıktıları, test edilen simülasyon koşulları kapsamında yaklaşık konum bilgisi olarak değerlendirilmektedir.

2.9 HSV Renk Analizi ve Yangın Risk Skoru Hesabı

Yangın tespiti sonucunda elde edilen her aday için model güven değerine ek olarak görsel renk bilgisi de değerlendirmeye alınmaktadır. Alev bölgelerinde sıklıkla görülen kırmızı, turuncu ve sarı renk bileşenleri ile yüksek parlaklığa sahip pikseller, HSV renk uzayında analiz edilmektedir. HSV renk uzayı, renk tonunun parlaklık değişiminden belirli ölçüde ayrıştırılabilmesi nedeniyle alev görünümünün destekleyici biçimde incelenmesinde kullanılmaktadır.

Bounding box içerisindeki kırmızı, turuncu, sarı ve parlak pikseller farklı ağırlıklarla değerlendirilerek renk skoru oluşturulmaktadır. Kırmızı ve turuncu pikseller aktif alev görünümünü daha güçlü temsil ettiği için daha yüksek ağırlıkla, sarı ve yüksek parlaklığa sahip pikseller ise daha düşük ağırlıklarla ele alınmaktadır. Renk analizi, model tespitinin yerine

geçen bağımsız bir sınıflandırma işlemi olarak değil, risk skorunu destekleyen ek bir bilgi kaynağı olarak kullanılmaktadır.

Her yangın adayı için hesaplanan risk skoru; renk skoru, yaklaşık alan skoru ve YOLO model güven değerinin ağırlıklı birleşiminden oluşmaktadır. Risk skoru aşağıdaki bağıntıyla hesaplanmaktadır:

$$\text{Risk Skoru} = 0,20 \times \text{Renk Skoru} + 0,30 \times \text{Alan Skoru} + 0,50 \times \text{Model Güveni}$$

Risk skoru hesabında kullanılan ağırlıklar, sistemdeki her bileşenin tespit güvenilirliğine katkısı dikkate alınarak sezgisel ve deneysel bir yaklaşımla belirlenmiştir. Bu kapsamda YOLO model güven değeri, yangın adayının model tarafından ne ölçüde yangın olarak algılandığını doğrudan ifade ettiği için en yüksek ağırlıkla değerlendirilmiştir. Bu nedenle model güveni için 0,50 ağırlığı kullanılmıştır. Yaklaşık alan skoru, tespit edilen yangın adayının göreceli büyüklüğünü temsil ettiğinden risk düzeyi üzerinde önemli fakat model güveninden daha destekleyici bir bileşen olarak ele alınmış ve 0,30 ağırlığı verilmiştir. HSV tabanlı renk skoru ise tespit edilen bölgenin alev görünümüyle uyumunu değerlendiren yardımcı bir görsel gösterge olarak kullanılmıştır. Renk bileşeni, parlak çevresel nesnelerden veya simülasyon sahnesindeki ışık değişimlerinden etkilenebileceği için 0,20 ağırlıkla sınırlandırılmıştır. Böylece toplam risk skoru, birincil karar bileşeni olan model güvenini merkeze alan; alan ve renk bilgisini ise destekleyici olarak kullanan dengeli bir yapı hâline getirilmiştir. Kullanılan ağırlıkların toplamı 1 olacak biçimde düzenlenmiş ve risk skorunun 0–1 aralığında yorumlanabilmesi sağlanmıştır.

2.10 Merkezî Veri Füzyonu ve Uzamsal Kümeleme

Sürü İHA görevinde aynı yangın odağı, farklı waypoint noktalarından veya birden fazla İHA tarafından tespit edilebilmektedir. Bu nedenle bireysel tespitlerin doğrudan harita üzerinde ayrı yangın noktaları olarak gösterilmesi, aynı yangının birden fazla kez temsil edilmesine ve görsel yoğunluğun yanıltıcı biçimde artmasına neden olabilir. Bu problemi azaltmak amacıyla İHA' lardan gelen tüm tespit sonuçlarını ortak bir yerde birleştirmekte ve işlenmektedir. Her İHA, tespit ettiği yangın adayının kimlik bilgisini, görev alanındaki yaklaşık konumunu, risk skorunu ve mevcutsa kalibrasyon verilerini merkezî sonuç kuyruğuna aktarmaktadır.

Birleştirme işleminin yapıldığı yerde, öncelikle belirlenen minimum risk skorunun altında kalan tespitleri değerlendirme dışı bırakmaktadır. Ardından birbirine yakın konumdaki tespitleri aynı yangın odağına ait gözlemler olarak değerlendirerek uzamsal kümeleme işlemi uygulamaktadır. Sistemde bir tespitin mevcut bir kümeye dahil edilmesi için küme merkezine olan uzaklığının 8 metre sınırı içerisinde bulunması gerekmektedir. Ayrıca sonradan birbirine yakın kaldığı belirlenen kümeler, 12 metre birleştirme mesafesi içerisinde tek bir küme altında toplanabilmektedir. Küme merkezinin hesaplanmasında, daha yüksek risk skoruna sahip tespitlerin konumsal değerlendirmeye daha fazla katkı sağlaması amacıyla skor ağırlıklı yaklaşım kullanılmaktadır.

Her küme için bir güven değeri hesaplanmaktadır. Bu güven değeri; kümedeki en yüksek tespit skoru, ortalama tespit skoru, gözlem sayısı, kümeye katkı sağlayan farklı İHA sayısı ve tespitlerin mekânsal tutarlılığından oluşmaktadır. Kullanılan güven hesabı aşağıdaki biçimdedir:

$$\begin{aligned} \text{Küme Güven} = & 0,35 \times \text{Maksimum Skor} + 0,25 \times \text{Ortalama Skor} \\ & + 0,20 \times \text{Gözlem Sayısı Skoru} + 0,10 \times \text{İHA Katılım Skoru} \\ & + 0,10 \times \text{Mekânsal Tutarlılık Skoru} \end{aligned}$$

Küme güveni hesabında kullanılan bileşenler, bir yangın kümesinin hem tespit kalitesini hem de gözlem tutarlılığını birlikte değerlendirecek şekilde seçilmiştir. Maksimum skor, küme içerisinde elde edilen en güçlü yangın tespitini temsil ettiği için 0,35 ile en yüksek ağırlığa sahiptir. Ortalama skor, kümedeki tüm tespitlerin genel güven düzeyini yansıttığından 0,25 ağırlıkla hesaba katılmıştır. Gözlem sayısı skoru, aynı bölgenin farklı karelerde veya waypoint noktalarında tekrar tespit edilmesini ifade eder ve 0,20 ağırlıkla değerlendirilmiştir. Farklı İHA sayısı, yangın bölgesinin birden fazla araç tarafından desteklenip desteklenmediğini gösterdiği için 0,10 ağırlıkla eklenmiştir. Mekânsal tutarlılık skoru ise küme içerisindeki tespitlerin birbirine yakınlığını temsil etmekte ve dağınık tespitlerin güven değerini düşürmektedir. Bu bileşen de 0,10 ağırlıkla hesaba katılmıştır. Böylece kullanılan ağırlıkların toplamı 1 olacak şekilde düzenlenmiş ve küme güven değeri 0–1 aralığında yorumlanabilir hâle getirilmiştir.


2.11 Risk Yoğunluk Haritası ve Harita Çıktılarının Oluşturulması

Doğrulanmış yangın kümeleri, görev alanındaki risk yoğunluğunu görselleştirmek amacıyla harita çıktısına aktarılmaktadır. Canlı harita üretiminde 1000×1000 piksel boyutunda bir yoğunluk matrisi kullanılmaktadır. Her doğrulanmış yangın kümesi, güven değerine bağlı bir yoğunluk noktası olarak harita üzerine işlenmekte ve Gaussian bulanıklaştırma yöntemiyle çevresine yumuşak geçişli bir görünüm kazandırılmaktadır. Elde edilen yoğunluk matrisi renk haritasına dönüştürülerek görev sırasında izlenebilir bir görsel çıktı hâline getirilmektedir. Görev sonunda, tespitler ve oluşturulan kümeler JSON biçiminde kayıt altına alınmaktadır. Bu kayıtlar içerisinde tespit noktaları, küme merkezleri, risk değerleri, ilgili İHA bilgileri ve kalibrasyon kullanıldığında hesaplanan hata bilgileri saklanabilmektedir. Ayrıca GPS koordinatı bulunan doğrulanmış kümeler kullanılarak OpenStreetMap tabanlı statik bir harita çıktısı oluşturulmaktadır.

Bu çalışmada oluşturulan ısı haritası, termal kamera veya sıcaklık sensörü aracılığıyla ölçülen fiziksel sıcaklık dağılımını temsil etmemektedir. Harita, görüntü tabanlı yangın tespiti, hesaplanan risk skorları ve doğrulanmış yangın kümeleri üzerinden elde edilen konumsal risk yoğunluğunu göstermektedir. Bu nedenle sistemin harita çıktısı, yangın görülen alanların konumsal değerlendirilmesine destek sağlayan görsel bir karar destek çıktısı olarak ele alınmaktadır.

Şekil 5'te, İHA'lardan elde edilen yangın tespitlerinin OpenStreetMap üzerinde risk yoğunluğu olarak gösterimi verilmiştir. Haritadaki renkli bölgeler, tespitlerin konumsal olarak

kümelenmesi ve hesaplanan risk skorlarının haritaya aktarılmasıyla oluşturulmuştur. Renkler düşük riskten yüksek riske doğru artan göreceli yangın risk seviyelerini göstermektedir.



Şekil 5. Risk yoğunluk haritası

2.12 Performans Değerlendirme Ölçütleri

Geliştirilen sistemin değerlendirilmesi iki düzeyde gerçekleştirilmiştir. İlk düzeyde, oluşturulan veri seti üzerinde eğitilen yangın tespit modelinin başarımı incelenmiştir. Model değerlendirmesinde precision, recall, mAP@0.5 ve mAP@0.5:0.95 ölçütleri kullanılmıştır. Bu ölçütler, modelin yangın nesnelerini doğru biçimde belirleyebilme ve yanlış tespitleri sınırlandırabilme düzeyini değerlendirmek amacıyla ele alınmıştır.

İkinci düzeyde, sürü İHA görev sisteminin oluşturduğu çıktılar incelenmiştir. Bu kapsamda görev sırasında elde edilen yangın tespitleri, doğrulanan yangın kümeleri, aynı kümeye katkı sağlayan İHA sayıları, risk skorları ve oluşturulan harita çıktıları değerlendirilmiştir. Kalibrasyon noktalarının kullanıldığı senaryolarda, sistem tarafından hesaplanan yangın konumları ile simülasyon ortamında önceden tanımlanan yangın konumları arasındaki hata değerlerinin hesaplanabilmesine yönelik altyapı kullanılmıştır.

Konum doğruluğuna ilişkin ölçümler, yalnızca uygulanan simülasyon senaryoları kapsamında yorumlanmıştır. Simülasyon ortamında elde edilen konum hatalarının gerçek saha koşullarındaki performansı doğrudan temsil ettiği kabul edilmemiştir. Bu yaklaşım doğrultusunda, geliştirilen prototipin yangın tespiti, sürü İHA verilerinin birleştirilmesi ve risk haritalama işlevlerini yerine getirme durumu değerlendirilmiştir.

3. BULGULAR

Bu bölümde, geliştirilen sürü İHA tabanlı yangın tespit ve risk yoğunluk haritalama sisteminden elde edilen deneysel bulgular sunulmaktadır. Bulgular öncelikle yangın tespit modelinin eğitilmesinde kullanılan veri seti ve model başarımı açısından değerlendirilmiş, ardından çoklu İHA tarama görevinin çalışabilirliği, waypoint tabanlı tespit süreci, merkezî veri füzyonu, uzamsal kümeleme ve harita çıktıları incelenmiştir. Son olarak, konumu önceden bilinen yangın noktaları üzerinden gerçekleştirilen kalibrasyon senaryosu kullanılarak sistemin yaklaşık konum üretme davranışı değerlendirilmiştir. Bu bölümde verilen sonuçlar, gerçek saha koşullarını doğrudan temsil eden kesin performans değerleri olarak değil, geliştirilen simülasyon prototipinin işlevsel doğrulamasına yönelik deneysel bulgular olarak ele alınmıştır.

3.1 Veri Setine İlişkin Bulgular

Dördüncü ara rapor döneminde, AirSim simülasyon ortamından elde edilen yangın görüntüleri üzerinde yeniden etiketleme ve veri temizleme çalışmaları gerçekleştirilmiştir. İlk etiketleme sürecinde alev sınırlarının değişken yapısı, birbirine yakın ateş bölgelerinin farklı biçimlerde işaretlenmesi ve parlak çevresel unsurların yangın görünümüne benzemesi nedeniyle etiketleme tutarsızlıkları belirlenmiştir. Bu nedenle veri seti yeniden değerlendirilmiş, yangın görünümünün yeterince belirgin olmadığı görüntüler veri setinden çıkarılmış ve birbirine yakın yangın bölgelerinin etiketleri ortak bir yaklaşım doğrultusunda düzenlenmiştir.

Yeniden düzenleme sonucunda veri seti, yalnızca "fire" sınıfını içeren toplam 1809 etiketli görüntüden oluşturulmuştur. Nihai veri setinin dağılımı Tablo 2'de verilmiştir.

Tablo 2. Nihai verisetinin dağılımı

Veri Kümesi	Görüntü Sayısı	Oran (%)
Eğitim	1447	79,99
Doğrulama	180	9,95
Test	182	10,06
Toplam	1809	100,00

Veri setinin yeniden düzenlenmesiyle, modelin daha tutarlı etiketlere sahip görüntüler üzerinde eğitilmesi sağlanmıştır. Belirsiz yangın görünümünün veri setinden çıkarılması ve etiketleme yaklaşımının ortaklaştırılması, model eğitimi açısından daha güvenilir bir veri yapısı oluşturmuştur.

Sürü İHA tarama sisteminin çalışabilirliğini nicel olarak gösterebilmek amacıyla örnek bir test koşusundan elde edilen görev çıktıları incelenmiştir. Bu test koşusunda 100×100 m büyüklüğündeki simülasyon alanı üç İHA tarafından taranmış ve her İHA kendisine atanan bölgede waypoint tabanlı zigzag rota izlemiştir. Görev sonunda İHA’lardan merkezî sunucuya toplam 67 ham yangın tespiti aktarılmıştır. Bu tespitler, merkezî sunucuda minimum skor filtresi ve uzamsal kümeleme işleminden geçirilmiş; birbirine yakın konumdaki tekrar eden tespitler aynı yangın bölgesi altında birleştirilmiştir. Kümeleme işlemi sonucunda 2 farklı yangın kümesi elde edilmiş ve bu kümelerin ikisi de doğrulanmış yangın bölgesi olarak değerlendirilmiştir. Bu sonuç, sistemin aynı yangına ait tekrarlı tespitleri azaltarak daha anlamlı ve yorumlanabilir yangın bölgeleri üretebildiğini göstermektedir.

Tablo 3. Örnek test koşusuna ait sürü İHA görev çıktıları

Ölçüt	Değer
Görev alanı	100 × 100 m
Kullanılan İHA sayısı	3
Toplam ham yangın tespiti	67
Drone1 ham tespit sayısı	26
Drone2 ham tespit sayısı	37
Drone3 ham tespit sayısı	4
Kümeleme sonrası yangın bölgesi sayısı	2
Doğrulanmış yangın kümesi sayısı	2
Aday küme sayısı	0
Küme 1 gözlem sayısı	28

Küme 2 gözlem sayısı	39
Küme 1 güven değeri	0,893
Küme 2 güven değeri	0,860
Risk yoğunluk haritası boyutu	1000 × 1000 px

Tablo 3’de görüldüğü üzere, örnek test koşusunda ham tespit sayısı 67 olmasına rağmen merkezî kümeleme sonrasında bu tespitler 2 yangın bölgesi altında toplanmıştır. Bu durum, aynı yangının farklı waypoint noktalarından veya farklı İHA’lar tarafından tekrar tespit edilmesi hâlinde sistemin bu gözlemleri tek bir yangın kümesi altında birleştirebildiğini göstermektedir. Ayrıca her iki kümenin de doğrulanmış olarak işaretlenmesi, kümelerin yeterli gözlem sayısına ve/veya birden fazla İHA katkısına sahip olduğunu göstermektedir. Bu sonuçlar, geliştirilen merkezî füzyon yapısının tekrarlı tespitleri azaltma ve harita çıktısını sadeleştirme işlevini yerine getirdiğini göstermektedir.

3.2 Yangın Tespit Modeline İlişkin Bulgular

Yangın tespit modeli için YOLO26 mimarisinin farklı varyantları değerlendirilmiştir. İlk eğitim deneyinde YOLO26x modeli kullanılmış, sonraki deneylerde ise daha düşük parametre sayısına sahip YOLO26m modeli üzerinde çalışılmıştır. Veri setinin yeniden düzenlenmesi ve veri artırma işlemlerinin genişletilmesi sonrasında, gerçekleştirilen deneyler içerisinde en yüksek performans YOLO26m modeliyle yürütülen uzun süreli eğitim sonucunda elde edilmiştir. Seçilen YOLO26m modelinin doğrulama ve test kümeleri üzerindeki performans değerleri Tablo 3’te verilmiştir.

Tablo 3. YOLO26m modelinin doğrulama ve test sonuçları

Veri Kümesi	Görüntü Sayısı	Yangın Örneği Sayısı	Precision	Recall	mAP@0.5	mAP@0.5: 0.95
Doğrulama	180	403	0,7978	0,7442	0,8247	0,5046
Test	182	402	0,8110	0,7790	0,7665	0,4750

Doğrulama kümesinde elde edilen 0,8247 mAP@0.5 değeri, modelin yangın bölgelerini belirli bir başarı düzeyinde ayırt edebildiğini göstermektedir. Test kümesinde mAP@0.5 değerinin 0,7665 olarak ölçülmesi ise modelin eğitim sürecinde doğrudan kullanılmayan simülasyon görüntüleri üzerinde de yangın tespiti gerçekleştirebildiğini ortaya koymaktadır. Doğrulama ve

test sonuçları arasındaki fark, çevresel görünüm, aydınlatma koşulları ve yangın biçimindeki değişkenliğin model performansı üzerinde etkili olabileceğini göstermektedir. Bu nedenle elde edilen sonuçlar, oluşturulan simülasyon veri seti kapsamındaki deneysel bulgular olarak değerlendirilmiştir.

3.3 Sürü İHA Tarama Sistemine İlişkin Bulgular

Geliştirilen sürü İHA mimarisinde görev alanı üç İHA arasında paylaştırılmış ve her İHA'nın kendisine atanan bölgede zigzag tarama rotası izlemesi sağlanmıştır. Böylece simülasyon ortamında tanımlanan görev alanının üç araç tarafından eş zamanlı biçimde taranabilmesi mümkün hâle getirilmiştir. Tarama noktalarının kamera kapsama alanı dikkate alınarak oluşturulması, görev alanının belirli bir düzen içerisinde gözlemlenmesine olanak sağlamıştır.

Her İHA, ziyaret ettiği waypoint noktalarında aldığı ardışık görüntüler üzerinde YOLO26m tabanlı yangın tespiti gerçekleştirmiştir. Yangın alevlerinin biçim ve parlaklık bakımından değişken olması nedeniyle aynı yangın bölgesi, ardışık görüntülerde farklı bounding box sonuçları oluşturabilmektedir. Bu nedenle aynı yangın adayına ilişkin tekrar eden tespitler PID tabanlı yöntemle işlenmiş ve tek kareye bağlı değişkenliğin azaltılması amaçlanmıştır.

Kararlı biçimde belirlenen yangın adayları için derinlik ve renk bilgileri değerlendirmeye dahil edilmiştir. Derinlik bilgisi, yangın adayının yaklaşık fiziksel büyüklüğünün ve konumsal karşılığının hesaplanmasında kullanılmıştır. HSV renk analizi ile elde edilen renk skoru ise model güven değeri ve yaklaşık alan bilgisiyle birlikte değerlendirilerek her yangın adayı için risk skoru oluşturulmasını sağlamıştır. Böylece sistemde yalnızca yangın adayının varlığı değil, tespit edilen bölgenin göreceli risk düzeyi de değerlendirilebilir hâle getirilmiştir.

3.4 Tespitlerin Ortak Yapıda Birleştirilmesi ve Haritalama Bulguları

Sürü İHA taraması sırasında aynı yangın bölgesinin farklı waypoint noktalarından veya birden fazla İHA tarafından tekrar gözlemlenebildiği belirlenmiştir. Bu nedenle bireysel tespitlerin doğrudan ayrı yangın noktaları olarak haritaya aktarılması yerine, elde edilen sonuçlar ortak bir değerlendirme ve haritalama yapısı içerisinde konumsal yakınlıklarına göre birleştirilmiştir.

Bu yapıda, düşük risk skoruna sahip tespitler değerlendirme dışında bırakılmış ve birbirine yakın konumdaki gözlemler aynı yangın bölgesine ait tespitler olarak kümelendirilmiştir. Aynı yangına ilişkin tekrar eden gözlemlerin tek bir küme altında birleştirilmesiyle, harita üzerinde aynı yangının birden fazla bağımsız bölge gibi gösterilmesinin önüne geçilmesi amaçlanmıştır. Ayrıca birden fazla İHA tarafından desteklenen veya yeterli sayıda gözlem içeren kümeler doğrulanmış yangın bölgeleri olarak değerlendirilmiştir.

Görev çıktıları incelendiğinde, doğrulanan yangın kümelerinin risk yoğunluk haritası üzerinde görselleştirilebildiği ve GPS bilgisi bulunan kümeler kullanılarak OpenStreetMap tabanlı statik harita çıktısının oluşturulabildiği görülmüştür. Üretilen ısı haritası, doğrudan sıcaklık ölçümüne dayalı termal bir harita olmayıp görüntü tabanlı yangın tespitleri ve hesaplanan risk skorları üzerinden oluşturulan konumsal risk yoğunluğunu ifade etmektedir.

3.5 Kalibrasyon Senaryosuna İlişkin Bulgular

Sistemin yangın bölgelerini tespit etme ve yaklaşık konum bilgisi üretme davranışını incelemek amacıyla, simülasyon ortamında konumları önceden tanımlanmış iki yangın noktası içeren bir kalibrasyon senaryosu değerlendirilmiştir. Bu senaryoda her iki yangın noktası da doğrulanmış yangın kümesi olarak belirlenmiştir. Elde edilen sonuçlar Tablo 4'te verilmiştir.

Tablo 4. Kalibrasyon senaryosunda yangın noktalarına ilişkin sonuçlar

Değerlendirme Ölçütü	Yangın 1	Yangın 2
Gerçek NED Konumu	(25,0; 25,0) m	(75,0; 75,0) m
Tespit Edilen Küme Merkezi	(25,1; 22,6) m	(74,1; 61,9) m
Yaklaşık Konum Hatası	2,4 m	13,0 m
Küme Güven Değeri	0,87	0,88
Küme Durumu	Doğrulanmış	Doğrulanmış

Kalibrasyon senaryosunda her iki yangın bölgesinin de iki farklı İHA tarafından gözlemlenerek doğrulanmış küme hâline getirilmesi, sürü İHA tespitlerinin ortak değerlendirme yapısı

içerisinde birleştirilebildiğini göstermektedir. Birinci yangın noktası için yaklaşık 2,4 m konum hatası elde edilirken, ikinci yangın noktası için hata yaklaşık 13,0 metre olarak hesaplanmıştır.

İki yangın noktası arasında ortaya çıkan hata farkı, konum kestirimi başarımının farklı sahne koşullarında değişebileceğini göstermektedir. İkinci yangın bölgesinde gözlenen daha yüksek sapmanın; yangının görüntü içerisindeki konumu, waypoint ile yangın arasındaki geometrik ilişki, derinlik bilgisinin kararlılığı, yangın efektinin görünür yüzeyi veya simülasyon sahnesindeki çevresel objeler ile ilişkili olabileceği değerlendirilmektedir. Ancak bu etkinin kesin olarak belirlenebilmesi için farklı yangın konumları ve farklı çevresel düzenler üzerinde ek deneylerin gerçekleştirilmesi gerekmektedir.

3.6 Genel Değerlendirme

Dördüncü ara rapor döneminde elde edilen bulgular, projenin veri seti hazırlama ve model eğitimi aşamasından, sürü İHA ile görev alanı taraması ve risk haritalama gerçekleştiren bütünleşik bir simülasyon prototipi aşamasına taşındığını göstermektedir. Yeniden düzenlenen veri seti üzerinde eğitilen YOLO26m modeli, test kümesinde 0,7665 mAP@0.5 değerine ulaşmıştır. Bu değer, modelin oluşturulan simülasyon görüntüleri üzerinde yangın tespiti gerçekleştirebildiğini göstermektedir.

Geliştirilen mimaride üç İHA'nın kendi görev bölgelerinde tarama gerçekleştirebildiği, yangın adaylarını görüntü üzerinden belirleyebildiği, derinlik ve renk bilgisini risk değerlendirme sürecine dahil edebildiği ve tespit sonuçlarının ortak bir haritalama yapısında birleştirilebildiği görülmüştür. Risk yoğunluk haritası ve OpenStreetMap tabanlı statik harita çıktıları, tespit edilen yangın bölgelerinin konumsal olarak görselleştirilebildiğini ortaya koymaktadır.

Bununla birlikte kalibrasyon senaryosunda yangın noktaları için elde edilen konum hatalarının farklılık göstermesi, konumlandırma yaklaşımının geliştirmeye açık olduğunu göstermektedir. Bu nedenle mevcut sonuçlar, sistemin tüm koşullardaki genel performansını ortaya koyan kesin sonuçlar olarak değil, geliştirilen mimarinin çalışabilirliğini gösteren ön bulgular olarak değerlendirilmiştir. Sonraki aşamada farklı yangın yerleşimleri ve farklı çevresel sahne düzenleri üzerinde ek testler gerçekleştirilerek sistemin tespit ve konumlandırma başarımının daha kapsamlı biçimde incelenmesi planlanmaktadır.

3.7 Çalışmanın Kısıtları ve Gelecek Çalışmalar

Bu çalışmada geliştirilen sistem, sürü İHA tabanlı yangın tespiti ve risk yoğunluk haritalama yaklaşımının simülasyon ortamında uygulanabilirliğini göstermek amacıyla tasarlanmış bir yazılım prototipidir. Bu nedenle elde edilen sonuçlar, gerçek saha koşullarındaki nihai sistem performansını doğrudan temsil etmemektedir. Çalışmanın en önemli kısıtlarından biri, deneylerin Microsoft AirSim ve Unreal Engine tabanlı simülasyon ortamında gerçekleştirilmiş olmasıdır. Simülasyon ortamı kontrollü testler yapmaya imkân sağlasa da gerçek orman yangınlarında görülebilecek rüzgâr, duman yoğunluğu, değişken aydınlatma, kamera titreşimi, görüş kaybı ve haberleşme gecikmesi gibi etkiler bu çalışmada sınırlı düzeyde temsil edilmiştir.

İkinci önemli kısıt, sistemde gerçek termal kamera kullanılmamış olmasıdır. Geliştirilen harita çıktısı sıcaklık ölçümüne dayalı termal harita değil, RGB görüntülerden elde edilen yangın tespitleri, renk analizi, yaklaşık alan hesabı ve model güven değerlerinden türetilen bir risk yoğunluk haritasıdır. Bu nedenle harita üzerinde gösterilen yoğunluk değerleri fiziksel sıcaklık değerleri olarak yorumlanmamalıdır.

Üçüncü kısıt, yangın konumunun hesaplanmasında kullanılan yaklaşımın yaklaşık kestirimlere dayanmasıdır. Konum hesabında İHA konumu, kamera görüş açısı, bbox merkezi, derinlik bilgisi ve yaw açısı birlikte kullanılmıştır. Ancak bbox merkezinin alevin gerçek fiziksel merkezini tam olarak temsil etmemesi, derinlik verisinin bazı durumlarda kararsız olması ve yangının görüntü içerisindeki konumunun perspektif etkilerinden etkilenmesi konum hatalarına yol açabilmektedir. Kalibrasyon senaryosunda farklı yangın noktaları için farklı hata değerlerinin elde edilmesi de bu kısıtı desteklemektedir.

Gelecek çalışmalarda sistemin farklı yangın yerleşimleri, farklı arazi yapıları, değişken ışık koşulları ve daha yoğun duman senaryoları altında test edilmesi planlanmaktadır. Ayrıca gerçek termal kamera veya RGB-termal birleşik algılama yapısının sisteme eklenmesi, konum kestirimi için daha gelişmiş kamera kalibrasyonu ve çoklu görüş geometrisi yöntemlerinin kullanılması, İHA'lar arası haberleşme gecikmelerinin modellenmesi ve gerçek donanım üzerinde saha testlerinin gerçekleştirilmesi sistemin güvenilirliğini artırabilecek önemli geliştirme adımlarıdır.

4. KAYNAKÇA

- [1] MacCarthy, J., Richter, J., Tyukavina, S., Weisse, M., & Harris, N. (2023). The latest data confirms: Forest fires are getting worse. World Resources Institute, 29.
- [2] Wasserman, T. N., & Mueller, S. E. (2023). Climate influences on future fire severity: a synthesis of climate-fire interactions and impacts on fire regimes, high-severity fire, and forests in the western United States. *Fire Ecology*, 19(1), 1-22.
- [3] Hepsiveri. (2025, Temmuz 10). 88 yıllık verilerle Türkiye'de orman yangınları. Hepsiveri. <https://hepsiveri.com/2025/07/88-yillik-verilerle-turkiyede-orman-yanginlari>
- [4] Andrew Smith. Ground-based sensors for wildfire monitoring: Challenges and opportunities. *Fire Safety Journal*, 42(1): 56–67, 2022.
- [5] Xie, X., Wang, J., Zhang, Y., Xin, J., Mu, L., & Xue, X. (2023, September). A uav forest fire detection method based on dual-light vision images. In 2023 CAA Symposium on Fault Detection, Supervision and Safety for Technical Processes (SAFEPROCESS) (pp. 1-6). IEEE.
- [6] Chen, X., Hopkins, B., Wang, H., O'Neill, L., Afghah, F., Razi, A., & Watts, A. (2022). Wildland fire detection and monitoring using a drone-collected RGB/IR image dataset. *IEEE Access*, 10, 121301–121317.
- [7] Xiao, N., Long, Y., Xianhong, Z., Xueping, X., Qi, L., & Yue, Z. (2025, June). Intelligent UAV Hill Fire Prevention System Based on Fire Detection Models. In 2025 IEEE 3rd International Conference on Image Processing and Computer Applications (ICIPCA) (pp. 1930-1934). IEEE.
- [8] Bakirci, M., & Bayraktar, I. (2024, September). Harnessing UAV Technology and YOLOv9 algorithm for real-time forest fire detection. In 2024 International Russian Automation Conference (RusAutoCon) (pp. 95-100). IEEE.
- [9] Georgiev, G. D., Hristov, G., Zahariev, P., & Kinaneva, D. (2020, October). Forest monitoring system for early fire detection based on convolutional neural network and UAV imagery. In 2020 28th National Conference with International Participation (TELECOM) (pp. 57-60). IEEE.
- [10] Bhargav, R., & Singh, P. (2025, March). Efficient UAV-Based Forest Fire Detection Using CNN and YOLOv8 Integration. In 2025 6th International Conference on Recent Advances in Information Technology (RAIT) (pp. 1-6). IEEE.

- [11] Ma, J., Wang, F., Liu, B., Lyu, Y., Tang, M., & Ji, Z. (2025, May). Grassland Fire Detection and Localization of UAV Based on Optimized YOLOv8s. In 2025 10th International Conference on Intelligent Computing and Signal Processing (ICSP) (pp. 544-549). IEEE.
- [12] Mughal, A. B., Haider, S. M., Khan, R. U., Shah, S. M. A., & Arain, J. H. (2025, April). FireSense: AI-Based Wildfire and Smoke Detection in Forests. In 2025 International Conference on New Trends in Computing Sciences (ICTCS) (pp. 522-527). IEEE.
- [13] Li, X., Zhang, W., Liu, L., & Xu, J. (2025). Exploring the Robustness: Hierarchical Federated Learning Framework for Object Detection of UAV Cluster. *IEEE Transactions on Mobile Computing*.
- [14] Zhang, H., & Hanzo, L. (2020). Federated learning assisted multi-UAV networks. *IEEE Transactions on Vehicular Technology*, 69(11), 14104-14109.
- [15] Ding, Y., Yang, Z., Pham, Q. V., Hu, Y., Zhang, Z., & Shikh-Bahaei, M. (2023). Distributed machine learning for uav swarms: Computing, sensing, and semantics. *IEEE Internet of Things Journal*, 11(5), 7447-7473.
- [16] El Hoffy, A., Kwon, S. S. C., & Yeh, H. G. (2023, April). Federated/deep learning in uav networks for wildfire surveillance. In 2023 Wireless Telecommunications Symposium (WTS) (pp. 1-9). IEEE.
- [17] Sharma, I., Gupta, S. K., Mishra, A., & Askar, S. (2023). Synchronous federated learning based multi unmanned aerial vehicles for secure applications. *Scalable Computing: Practice and Experience*, 24(3), 191-201.
- [18] Wu, F., Dong, C., Qu, Y., Sun, H., Zhang, L., & Wu, Q. (2022, October). CIOFL: Collaborative inference-based online federated learning for UAV object detection. In 2022 IEEE 19th International Conference on Mobile Ad Hoc and Smart Systems (MASS) (pp. 258-259). IEEE.
- [19] Wong, Y. J., Tham, M. L., Kwan, B. H., Gnanamuthu, E. M. A., & Owada, Y. (2022). An optimized multi-task learning model for disaster classification and victim detection in federated learning environments. *IEEE Access*, 10, 115930-115944.
- [20] Papakostas, L., Geladaris, A., Mastrogeorgiou, A., Sharples, J., Hattenberger, G., & Chatzakos, P. (2025). Optimized area coverage in disaster response utilizing autonomous UAV

swarm formations. In 2025 33rd Mediterranean Conference on Control and Automation (MED). IEEE.

[21] Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems*, 2, 429-450.